NOTE MÉTHODOLOGIQUE

DÉMARCHE DE MODÉLISATION

Table des matières

Introduction

Cette note méthodologique est issue du projet 7 d´openclassrooms de data science intitulé “Implémentez un modèle de scoring”

Le Projet

La société “Prêt à dépenser”, propose des crédits à la consommation pour des personnes ayant peu ou pas du tout d'historique de prêt. L’entreprise souhaite mettre en œuvre un outil de “scoring crédit”.

La modèle à créer consiste en un modèle de scoring, fournissant une probabilité. Cette probabilité représente le risque de défaut du client lors de son crédit.

Des modélisations déjà existantes sont disponibles depuis la plateforme Kaggle. Les données collectées issu de cette même plateforme représentent 300 000 clients. Une centaine de variables décrit chacun des clients (score issu d´outil exterieure, revenus , durée du credit etc.)

Démarche de modélisation

Entrainement du modele

Le jeu de données a été séparé en un jeu d´entrainement et de test (80%/20%) afin de réduire le risque sur-apprentissage.

La cible de ce modèle est distibuée de façon assez désequilibré (92%/8%), un équilibrage des données a été réalisé grâce à la librairie SMOTE.

Les hyperparamètres ont été optimisé via la méthode RandomizedSearchCV, les hyperparamamètres sont ceux de la librairie SMOTE ainsi que ceux de l´algorithme en tant que tel.

Les algorithmes étudiés sont ceux de la famille des modèles ensemblistes (random forest, light gbm). Une référence a été prise avec un modèle naif.

Fonction coût métier, l'algorithme d'optimisation et métrique d'évaluation

Fonction Cout

Une fonction coût a été mis en place à partir des valeurs “vrai positif”, “vrai negatif”, “faux positif” et “faux negatif”.

Ces valeurs peuvent être représentées par une matrice de confusion.

Plusieurs combinaisons -en pondérant ces valeurs- ont été testé. Ici, on a cherché à minimiser les erreurs produites sur les prédictions des clients pouvant vraiment faire défaut. Au final, on a minimisé la valeur faux négatif + vrai négatif.

Ce cout est programmé dans une fonction et peut être amener à évoluer si le client souhaite réaliser un arbitrage différent pour sa prise de décision.

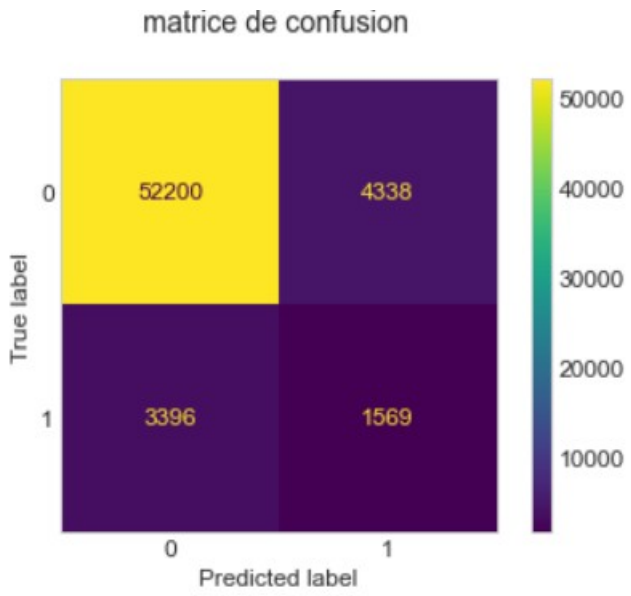

Algorithme d´optimisation

L´algorithme utilisé est l´algorithme de boosting ligthGBM.

Il s´agit d´un modèle ensembliste permettant d´intégrer des variables catégorielles sans encodage “one hot encoder”. Le temps de calcul est optimisé par rapport aux algorithmes le précédent. Des options existent aussi pour réaliser du calcul distribué.

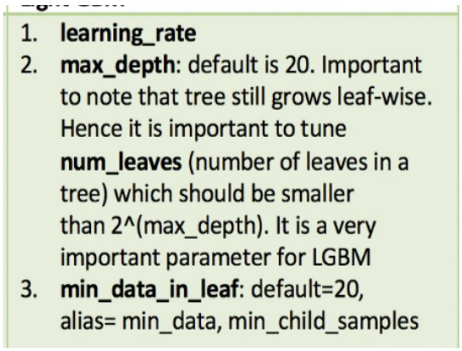

1. **learning_rate**
2. **max_depth**: default is 20. Important to note that tree still grows leaf-wise. Hence it is important to tune **num_leaves** (number of leaves in a tree) which should be smaller than 2^(max_depth). It is a very important parameter for LGBM
3. **min_data_in_leaf**: default=20, alias= min_data, min_child_samples

Paramètres controlant le surapprentissage

Metrique d´evalution

On étudie un problème de classification binaire, on peut donc utiliser comme métrique les valeurs de roc-auc (aire sous la courbe), de précision, de sensibilité ainsi qu´une matrice de confusion. La métrique d´optimisation utilisé est celle décrite précédemment pour la fontion coût.

Une métrique observée est la matrice de confusion :

		Classe réelle	
		-	+
Classe prédite	-	True Negatives *(vrais négatifs)*	False Negatives *(faux négatifs)*
	+	False Positives *(faux positifs)*	True Positives *(vrais positifs)*

Matrice de confusion

Les autres métriques :

Avec TN:True Negatives, TP: True Positives, False Negatives:FN, False Positives:FP.

- accuracy = (TN+TP) / (TN+TP+FN+FP), proportion d´erreur globale
- précision = TP/(TP+FP), proportion de prédictions correctes parmi les points prédits positifs
- sensibilité = TP/(TP+FN) , proportion de positifs correctement identifiés

L´évaluation actuelle du modèle donne les valeurs suivantes:

- accuracy ~ 0,75
- précision ~ 30%
- sensibilité ~ 30%

L'interprétabilité du modèle

Feature Importance

Les variables influentes principales du modèle sont représentées dans le graphique ci-dessous:

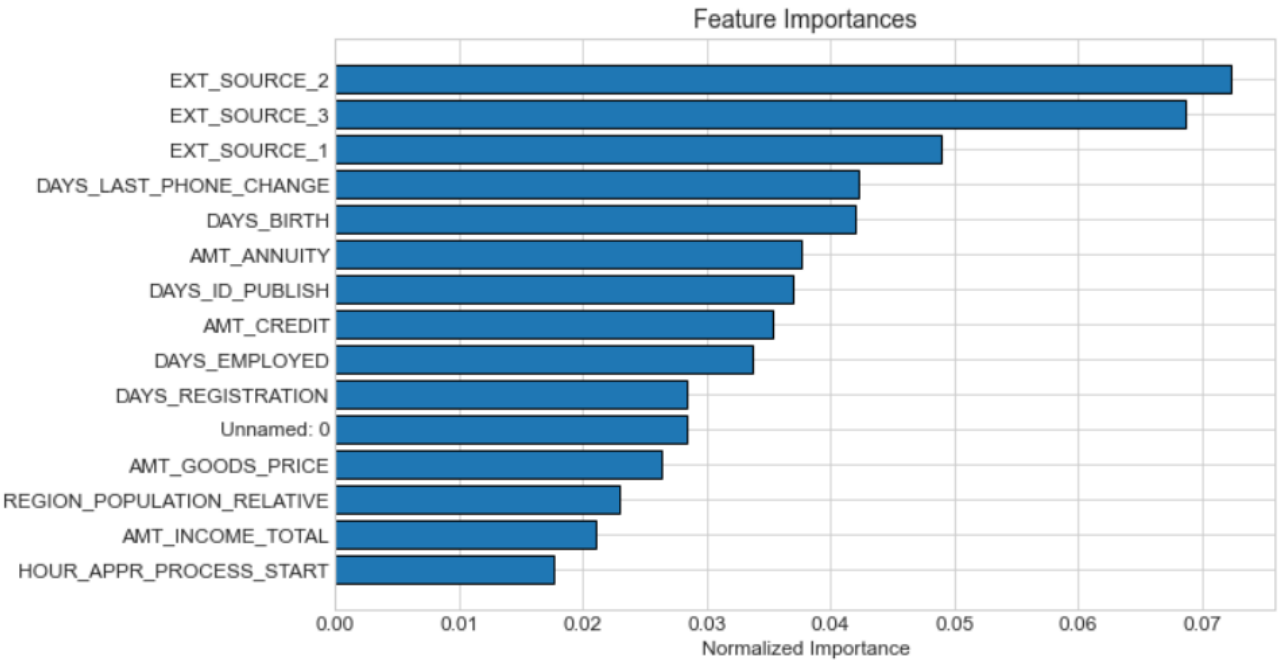

A partir de ces variables, on peut déduire une première liste de variables intéressantes pour la création du dashboard, correspondant à des notions métiers:

- EXT_SOURCE_ : score provenant d´un calcul externe
- AMT_ANNUITY : annuité
- AMT_CREDIT : montant du crédit
- DAYS_EMPLOYED : nombre de jours en emploi
- AMT_GOODS_PRICE : montant du bien
- AMT_INCOME_TOTAL : ressources du client

SHAP

La librairie shap permet d´étudier l´interprétation locale (et globale) du modèle.

Par exemple localement, pour un client, on peut visualiser dans quelle mesure les variables contribuent au calcul de son score particulier (ici les annuités, le score externe 3, etc.):

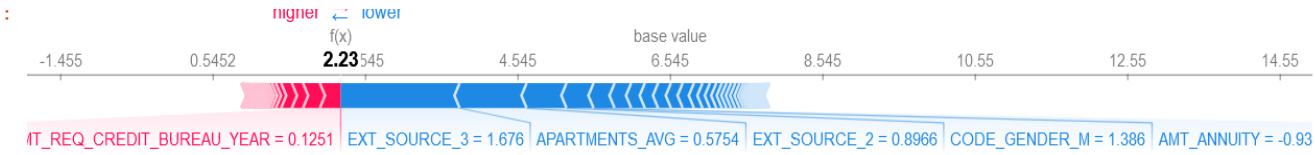

Les limites et les améliorations envisageables, performance et interprétabilité

Ce modèle présente des performances en terme de sensibilité de 30% et de 75% d´accuracy. Cela permet d´offrir une première orientation dans l´évaluation du risque d´octroi de crédit.

Une voie possible d´amélioration est le feature engineering qui est assez complexe à réaliser de part le manque de transparence des variables extérieures et du nombre de variables en jeu.

Une alternative est de se documenter sur kaggle pour trouver un feature engineering plus abouti.

Une autre voie d´amélioration est la sélection de modèle compatible avec ce type de donnée comme des réseaux de neurones, qui pourrait permettre de simplifier l´étape de création de variables.

Le point essentiel, ici, est de pouvoir bénéficier du retour d´expérience de personnes du métiers afin de définir correctement les bonnes variables et algorithmes. Il peut s´agir d´une première étape afin de converger avec le client vers des modèles plus performant en capacité de prédiction.

Annexe

Librairie SMOTE: (https://imbalanced-learn.org/)

Lemaître, Guillaume, Fernando Nogueira, et Christos K. Aridas. « Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning ». *Journal of Machine Learning Research* 18, n° 17 (2017): 1-5.
http://jmlr.org/papers/v18/16-365

Librairie SHAP: (https://shap.readthedocs.io/)

Lundberg, Scott M, et Su-In Lee. « A Unified Approach to Interpreting Model Predictions ». In *Advances in Neural Information Processing Systems 30*, édité par I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, et R. Garnett, 4765-74. Curran Associates, Inc., 2017. http://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf.

LightGBM: (https://lightgbm.readthedocs.io)

Ke, Guolin, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, et Tie-Yan Liu. « LightGBM: A Highly Efficient Gradient Boosting Decision Tree ». In *Advances in Neural Information Processing Systems*, édité par I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, et R. Garnett, Vol. 30. Curran Associates, Inc., 2017.
https://proceedings.neurips.cc/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf.